

МАГИСТРАТУРА ИТМО. Эффект ИТ
22.08. Домашнее задание ИТ.

2026

1) FLOPS

Ф. о. обозначения:

S - ширина исходного изображения

B - batch-size

D_{input} , D_{output} кол-во входных и выходных каналов слоя

K - размер ядра

P - padding

T - stride

K_{input} , K_{output} - пространственный размер входа и выхода слоя

1. Формула расчета ширины

$$K_{output} = (K_{input} - K + 2P) / T + 1$$

$$Flops_{conv} = B \cdot 2 \cdot D_{input} \cdot K^2 \cdot D_{output} \cdot K_{output}^2$$

2. Flops блока (conv + batch_norm, ReLU)

$$B \cdot D_{output} \cdot K_{output}^2 \cdot (2 \cdot D_{input} \cdot K^2 + 5)$$

Формулы

$$\text{FLOPS pool} = B \cdot \text{Input} \cdot K_{\text{output}}^2 \cdot (K^2 - 1)$$

3. Параметры сети

$$K_2 = \text{ceil}(S/2)$$

$$K_4 = \text{ceil}(S/4)$$

$$K_8 = \text{ceil}(S/8)$$

$$K_{16} = \text{ceil}(S/16)$$

Компоненты.

• Conv1 + Batch Norm + Relu:

$$B = 8586 \cdot K_2^2$$

• Conv2 + Batch Norm + Relu:

$$B = 102220 \cdot K_4^2$$

• Conv3 + Batch Norm + Relu:

$$B = 148086 \cdot K_8^2$$

• Conv4 + Batch Norm + Relu:

$$B = 66816 \cdot K_{16}^2$$

• Conv5 + Batch Norm + Relu:

Исходные данные:

Adaptive Avg Pool: $B \cdot 512 \cdot K_{16}^2$

Linear:

$512 \rightarrow 256$; $B \cdot (2 \cdot 512 \cdot 256 + 256)$

Relu: $B \cdot 256$

Linear: ~~256~~

$256 \rightarrow 100$; $B \cdot (2 \cdot 256 \cdot 100 + 100)$

Умножение формул

$FLOPs(S, B) =$

$$= B \cdot (3568 \cdot \text{ceil}(S/2)^2 + 102876 \cdot \text{ceil}(S/4)^2 + \\ + 214812 \cdot \text{ceil}(S/8)^2 + 1446144 \cdot \text{ceil}(S/16)^2 + \\ + 313856)$$

Для конвейера:

$$\underline{FLOPs(S, B) = B \cdot (17835 \cdot S^2 + 313856)}$$

2) Получено (Нечисло):

из предыдущего, выделено в число

свершилось - 883 286 чисел

Ваше число: 4892 чисел

следующее число: 157 028 чисел

Ваше число: 6.8 Бит

$$\text{Итого: } 4 \cdot (883\,286 + 4892 + 157\,028) + 6.8 =$$

$$= 4\,181\,312 \text{ Бит}$$

Таким образом, получено:

использовано Бит: $3BS^2$ - чисел

выбор. Соств. $8BS^2$ чисел

$$\text{Итого } (S, B) =$$

$$= 4 \cdot (3BS^2 + 8BS^2 + 8BS^2) = 76BS^2 \text{ Бит}$$

Итого:

$$\text{Нечисло } (S, B) = 4\,181\,312 + 76BS^2 \text{ Бит}$$

3 Bytes moved:

целовой.

- все операции можно ускорить
- у переопределения переменных

Примеры

1) Conv1

BN1

Relu1

MaxPool

Прочитано + Записано, ~~Sp3L~~ Sp3L

$$3BS^2 + 4704 + 8BS^2$$

$$8BS^2 + 128 + 8BS^2$$

$$8BS^2 + 8BS^2$$

$$8BS^2 + 2BS^2$$

2) Conv2

BN2

Relu2

$$2BS^2 + 51200 + 4BS^2$$

$$4BS^2 + 256 + 4BS^2$$

$$4BS^2 + 4BS^2$$

3) Conv3

BN3

Relu3

$$4BS^2 + 73728 + 2BS^2$$

$$4BS^2 + 104 + 4BS^2$$

$$4BS^2 + 4BS^2$$

ПЧК

Больше будет еще меньше!

... Умно

$$131BS^2 + 88328B + 4882 \text{ умно в fp32}$$

Адаптивный пул:

Adaptive Avg Pool: умно $2BS^2$, заменил $512B$

Linear: $512B + 431328$ умно, $256B$ заменил

Relu $256B$ заменил, умножил

Linear $256 \rightarrow 100$: прокинул $256B + 25700$ весов, заменил $100B$

$$\text{Умно. } 2BS^2 + 2148B + 157028 \text{ весов в fp32}$$

Умно 2 весов:

Bytes Moved ($\frac{1}{2}B$)

$$4 \cdot (133BS^2 + 2148B + 1045316) =$$

$$= 532BS^2 + 8592B + 4181264 \text{ байт}$$

ПЧК

Handwritten signature

4) Latency

из того что было.

$$F(S, B) = B \cdot (17835S^2 + 313856) \text{ Flops}$$

$$Q(S, B) = 532BS^2 + 8532B + 4181264 \text{ байт}$$

Latency

$$\text{Latency}(S, B, Q, L) = \tau + \max(\text{Flops}, \text{memory})$$

$$\text{Flops} = B \cdot (17835S^2 + 313856) / C,$$

$$\text{memory} = (532BS^2 + 8532B + 4181264) / W$$

$$QL = (\tau, C, W)$$

τ - постоянная задержка на запуск forward'a в серверах

C - flops/c, производительность сервера

W - производительность пропускной способности сервера, байт/c

5) Energy

$$\text{Energy}(S, B, Q-E) =$$

$$= P \cdot \text{latency}(S, B, Q-L) +$$

$$+ \varepsilon_F \cdot B \cdot (17835S^2 + 313356)$$

$$+ \varepsilon_M \cdot (532BS^2 + 8532B + 4181284)$$

$$Q-E = (E, C, W, P, \varepsilon_F, \varepsilon_M)$$

P - базовая мощность всего GPU, Ватт

ε_F - гол. энергия на 1 Flop, Дж / Flop

ε_M - гол. энергия на один байт передан. байт Дж / байт

• Порядок констант кс 74

$$Q = 0,000554 \text{ сек}$$

$$C = 2,405113e+12 \text{ Flops/s}$$

$$W = 29383345243,3 \text{ байт/с}$$

$$P = 52,3244324881 \text{ W}$$

$$\varepsilon_F = 5,01888e-12 \text{ J/Flop}$$

$$\varepsilon_M = 3,45306803748e-31 \text{ J/байт} \approx 0$$